

Распознавание текста на основе скелетного представления толстых линий и сверточных сетей*

А. С. Лукоянов¹

lukoyanov.as@phystech.edu

¹МФТИ

Аннотация: Данная работа посвящена решению задачи оптического распознавания символов при помощи скелетного представления. Такой подход имеет несколько недостатков, один из них заключается в неприменимости традиционных сверточных нейронных сетей на графовых структурах, которые и являются результатом скелетизации символов. В данной работе мы предлагаем способ свертывания графовых структур, позволяющий породить информативное описание скелета толстой линии. Также приводится сравнительный анализ архитектур, работающих непосредственно на растровом представлении символов и архитектур, использующих графовое представление символов. Для этих целей используется классический в подобных задачах набор данных MNIST, на котором нам удалось добиться значимого повышения качества распознавания толстых линий за счет нового способа порождения их описаний.

Ключевые слова: классификация символов; распознавание текста; графовые структуры; скелетное представление; свертки.

DOI: 10.21469/22233792

1 Введение

Задача оптического распознавания символов уже стала классической среди задач компьютерного зрения. Несмотря на то, что качество существующих моделей довольно высоко, каждый год выходит множество научных работ, посвященных именно классификации символов [1] [2]. Основным подходом к решению таких задач стали архитектуры, использующие сверточные слои [3] [4]. Традиционно, входом таких алгоритмов является растровое изображение, но, тем не менее, существует более комплексный подход, при котором растровое изображение сначала переводится в векторное представление путем построения скелета символа, то есть графовой структуры, а потом подается на вход обучаемой модели.

Наиболее общий подход к скелетизации представляет собой процесс заполнения внутренних областей символов кругами, центры которых - будущие вершины графа, соединяются будущими ребрами графа. Например, в работе [5] обсуждается моделирование рукописного текста с помощью жирных линий. В работе [6] проводится сравнение формы бинарных растровых изображений на основе скелетизации. Однако, существует и альтернативные методы, как, например описанный в работе [7].

При этом, применение сверточных нейронных сетей на векторном представлении изображений является нетривиальной задачей, в следствии того, что традиционные методы свертки неприменимы для таких структур данных.

Среди задач оптического распознавания символов и задач компьютерного зрения в целом особое место занимает задача классификации рукописного текста MNIST [8]. Большое количество работ, в том числе и современных, используют данную выборку для валидации

*Работа выполнена при финансовой поддержке РФФИ, проекты № 00-00-00000 и 00-00-00001.

и сравнения предложенных архитектур, как в работах [9] [10]. Например, в докладе [11] рассматривается многозадачное обучение на данных MNIST.

2 Постановка задачи

Введем следующие обозначения:

- \mathbb{I} - множество бинарных изображений символов из алфавита \mathbb{A} . На изображении содержится только один символ и площадь описанной вокруг него окружности близка к площади окружности вписанной в квадрат изображения. При этом считаем, что для каждого элемента из \mathbb{I} известна метка класса $y \in \mathbb{A}$. Тогда, пусть функция $a : \mathbb{I} \rightarrow \mathbb{A}$ однозначно сопоставляет каждому изображению из \mathbb{I} его метку класса.
- \mathbb{G} - множество скелетных представлений изображений, где под скелетным представлением подразумевается неориентированный граф, каждой вершине которого сопоставлено некоторое число, называемое радиусом. Функция $g : \mathbb{I} \rightarrow \mathbb{G}$ однозначно сопоставляет каждому изображению из \mathbb{I} его скелетное представление. В данной работе в качестве такой функции используется алгоритм, описанный в работе [5].
- \mathbb{F} - множество признаков, описывающих скелетное представление символов. Получение конкретного вида этих признаков является одной из задач данной работы. Функция $f : \mathbb{I} \rightarrow \mathbb{G}$ однозначно сопоставляет каждому элементу из \mathbb{G} множество его признаков.

Тогда, задачей данной работы, является построение таких функций

$$\hat{a}_1 : \mathbb{I} \rightarrow \mathbb{A}$$

$$\hat{a}_2 : \mathbb{G} \rightarrow \mathbb{A}$$

$$\hat{a}_3 : \mathbb{F} \rightarrow \mathbb{A}$$

, что они минимизируют соответствующие функции потерь:

$$L(\hat{a}_1, a)$$

$$L(\hat{a}_2(g), a)$$

$$L(\hat{a}_3(f(g)), a)$$

, где $L(a, b)$ - функция кросс энтропии двух функций a и b на выборке изображений \mathbb{I} .

3 Описание эксперимента

Выполненная работа состоит из нескольких частей, каждую из которых рассмотрим подробнее:

1. Обучение базовой модели

В качестве базовой модели было решено выбрать ставшую уже классической для таких задач модель сверточной нейронной сети. Данная модель хорошо зарекомендовала себя в задачах классификации изображений и используется во многих работах в качестве базовой модели. С помощью данной модели было получено качество ассигасу 99,25% на тестовой выборке после 12 эпох.

2. Планирование эксперимента

Одной из частей данного исследования являлось планирование эксперимента, в результате которого было получено представление о цели эксперимента, процессе сравнения алгоритмов, были спланированы таблицы и алгоритм анализа ошибок.

3. Отбор признаков

В процессе построения такой модели возник ряд сложностей. Одной из них стало то, что графовое описание имеет нефиксированный размер, что приводит к невозможности обучения модели непосредственно на скелетизированном изображении.

Для того чтобы решить эту проблему мы составили статистические признаки, которые в общем случае не зависят от количества ребер и вершин в графе. Статистические признаки, которые мы использовали в данной работе это наименьшее, наибольшее, среднее значение и стандартное отклонение вычисленные на распределении каждой из следующих сущностей:

- Координата X каждого ребра, представленного в виде вектора.
- Координата Y каждого ребра, представленного в виде вектора.
- Угол наклона каждого ребра.
- Длина каждого ребра.
- Координата X каждой вершины.
- Координата Y каждой вершины.
- Радиус каждой вершины.

Так же, помимо описанных выше признаков, было добавлено количество вершин и гистограмма направлений. Под гистограммой направлений подразумевается 10 целых чисел, каждому из которых сопоставлен один из 10 равных секторов, разделяющих окружность. Каждое число отображает количество векторов, направленных в данный сектор.

Итого, таким образом было получено 39 признаков.

4. Выбор модели

Основываясь на физическом смысле сгенерированных признаков в качестве модели были выбраны решающие деревья, а именно градиентный бустинг над ними. Одной из самых лучших библиотек, реализующих градиентный бустинг является Lightgbm.

5. Анализ структуры модели

Было решено, что структурными параметрами, согласно которому модель выбирается из множества моделей, выбрано $n_{estimatorsnumleaves}$, :

- $learning_rate : 0.1$
- $n_{estimators} : 100$
- $numleaves : 30$

После обучения, было получено качество 92,23%

6. Оптимизация гиперпараметров

Для оптимизации гипер-параметров был запущен grid-search, в результате чего точность получено оптимальные значения гипер-параметров:

- $learning_rate : 0.3$
- $n_{estimators} : 300$
- $numleaves : 50$

Обучив модель с такими параметрами было получено качество (ассигасу) 93,80%.

Анализ ошибок. Важной частью исследования является анализ ошибок. Получив, описанную выше модель и перебрав гипер-параметры, мы изучили примеры изображений,

на которых полученная модель дает неверный результат. В подавляющем большинстве случаев, на этих изображениях граф скелетного представления недостаточно хорошо приближал нарисованную цифру. Связано это было с тем, что некоторые цифры содержат слишком тонкие или короткие участки, на которых алгоритм скелетизации не способен построить адекватное приближение графом. Пример можно увидеть на изображении 1. В следствии этого был сделан вывод, что для дальнейшего улучшения качества системы, требуется более тонкая подстройка алгоритма скелетизации.




Рис. 1 Пример некорректной скелетизации

Анализ ошибок.

Проведенный эксперимент показал, что построение модели на скелетизации изображения символов изображения может дать конкурентноспособный результат. Тем не менее, такие модели все еще проигрывают по качеству обученным на изначальных изображениях сверточным нейронным сетям.

В следствии анализа ошибок было обнаружено несколько ошибок алгоритма скелетизации и сделан вывод о том, что для дальнейшего улучшения качества модели имеет смысл улучшать алгоритм извлечения скелетного представления.

Литература

- [1] Zou, Xianli Fast Convergent Capsule Network with Applications in MNIST—Advances in Neural Networks – ISNN 2018—Springer International Publishing— pp. 3–10
- [2] Palvanov A., Im Cho Y Comparisons of deep learning algorithms for MNIST in real-time environment—International Journal of Fuzzy Logic and Intelligent Systems—2018. – Т. 18. – №. 2. – С. 126-134.

- 117 [3] *LeCun Y. et al.* Convolutional networks for images, speech, and time series //The handbook of
118 brain theory and neural networks. – 1995. – Т. 3361. – №. 10. – С. 1995.
- 119 [4] *Ciresan D. C. et al.* Convolutional neural network committees for handwritten character
120 classification //Document Analysis and Recognition (ICDAR), 2011 International Conference on.
121 – IEEE, 2011. – С. 1135-1139.
- 122 [5] *Клименко С. В., Местецкий Л. М., Семенов А. Б.* Моделирование рукописного шрифта с
123 помощью жирных линий //Труды. – 2006. – Т. 16.
- 124 [6] *Кушнир О. и др.* Сравнение формы бинарных растровых изображений на основе скелетизации
125 //Машинное обучение и анализ данных. – 2012. – Т. 1. – №. 3. – С. 255-263.
- 126 [7] *Масалович А., Местецкий Л.* Распрямление текстовых строк на основе непрерывного
127 гранично-скелетного представления изображений //Труды Международной конференции
128 «Графикон», Новосибирск.–2006.–4 с.
- 129 [8] *LeCun Y., Cortes C., Burges C. J.* MNIST handwritten digit database // Available: <http://yann.lecun.com/exdb/mnist>. – 2010. – Т. 2.
- 131 [9] *Zhu D. et al.* Negative Log Likelihood Ratio Loss for Deep Neural Network Classification //arXiv
132 preprint arXiv:1804.10690. – 2018.
- 133 [10] *Nair P., Doshi R., Keselj S.* Pushing the limits of capsule networks //Technical note. – 2018.
- 134 [11] *Hsieh P. C., Chen C. P.* Multi-task Learning on MNIST Image Datasets. – 2018.

135 *Поступила в редакцию 01.01.2017*